Задача по Комбинационному рассеянию света

IT-дно

Пантенков Роман

Садиковская Елизавета

Приходько Павел

07.03.2026

1 Описание подхода

1.1 Предобработка

1. Для начала мы собираем всю информацию со свех файлов что у нас есть. Те точки для которых <= 10 измерений мы отбрасываем, а остальные точки мы группируем по областям мозга и по классам.

2. Дальше мы интерполируем значения intensity и вычисляем их при wave = 900, wave = 901, ... , wave = 3500. На данном этапе наш датафрейм состоит из колонок: wave900, ... , wave3500, brain_region, wave_category, class.

3. Чтобы увеличить гладкость графика и понизить влияние флуорисцентного излучения, мы сглаживаем значения с помощью фильтра Савицкого-Голея, корректируем `baseline` с помощью ARPLS, обнуляем минимум и убираем отрицательные значения, и векторно нормализуем (L2)

4. Далее, перед обучением мы нормализуем числовые значения и с помощью `OHE` кодируем `brain_reigon`. Также мы выбрасываем промежуток с 2000 по 2400, так как в нем у нас нет нормальных данных.

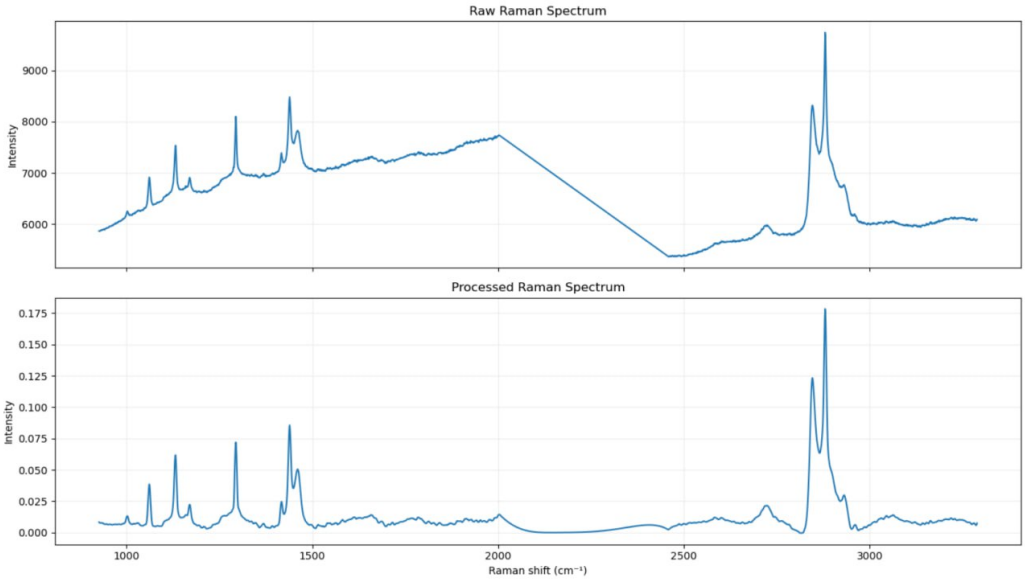

Рис. 1: До/после препроцессинга

Также, по началу мы использовали `PCA`, он давал хороший прирост точности модели, так как делал данные более независимыми, однако мы решили отказаться от его использования, ведь для дополнительного задания нам нужно было определить наиболее важные параметры (что явно несовместимо с `PCA`)

1.2 Тип модели и тренировка

Мы опробовали большое количество разных моделей, но в итоге остановились на `RandomForestClassifier`. Он позволяет сосредоточиться только на важных спектрах и при этом не слишком сильно переобучается.

1.3 Полученные метрики

Мы прогнали нашу модель через кросс-валидацию

```
CV scores: [0.81570824 0.81387904 0.81683055 0.81580151 0.80997027]
Mean CV: 0.8144379239129413
```

Так-же мы получили остальные метрики:

```
Training RandomForest...
Training trees: 100%|██████████| 300/300 [18:23<00:00,  3.68s/it]
              precision    recall  f1-score   support

     control       0.75      0.78      0.76     12600
        endo       0.82      0.72      0.77     11498
         exo       0.74      0.79      0.76     13230

    accuracy                           0.76     37328
   macro avg       0.77      0.76      0.76     37328
weighted avg       0.77      0.76      0.76     37328

Top 20 important features:
brain_region_cerebellum    0.034332
brain_region_cortex        0.014484
wave2883                   0.008441
wave1439                   0.008321
wave1438                   0.007508
wave2881                   0.007103
wave1440                   0.007066
wave2882                   0.006832
wave1441                   0.006609
brain_region_striatum      0.006471
wave1437                   0.006412
wave2846                   0.006376
wave2843                   0.006352
wave2853                   0.006135
wave2879                   0.006111
wave2885                   0.005910
wave2845                   0.005902
wave2847                   0.005881
wave2848                   0.005868
wave2849                   0.005807
dtype: float64
```

Рис. 2: Метрики

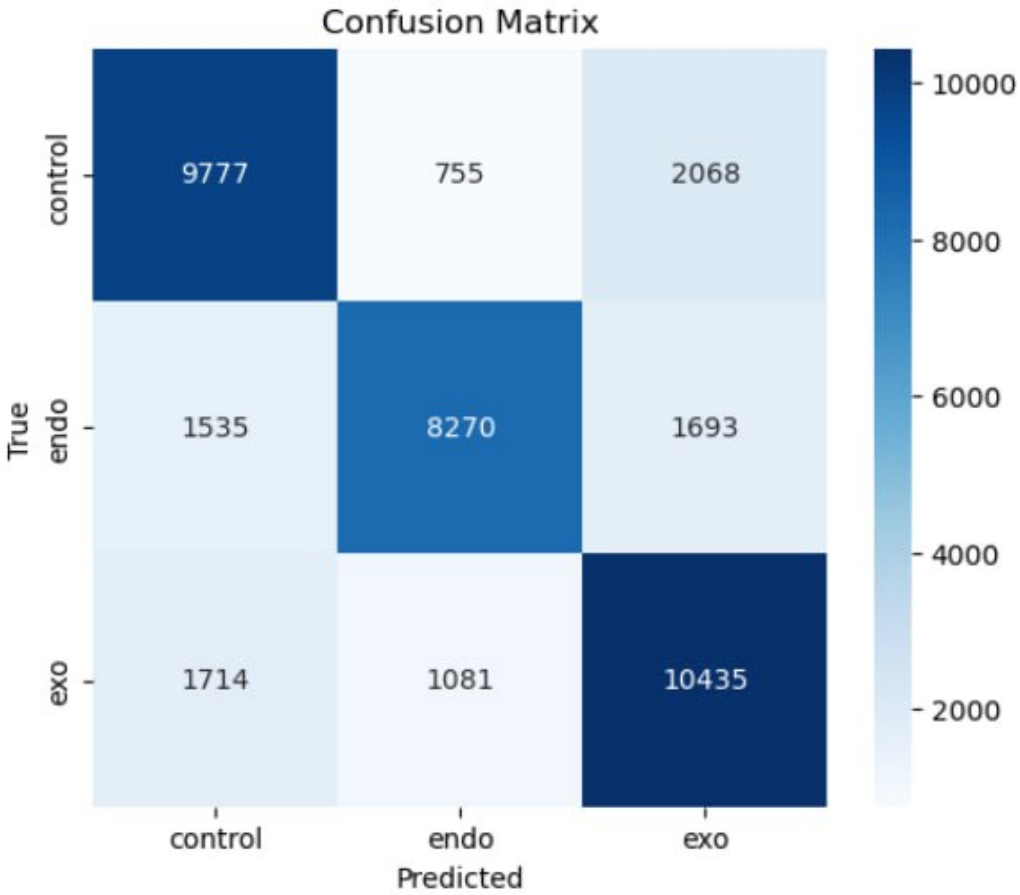

Рис. 3: Confusion matrix

2 Дополнительное задание

Мы нашли наиболее важные для нас частоты:

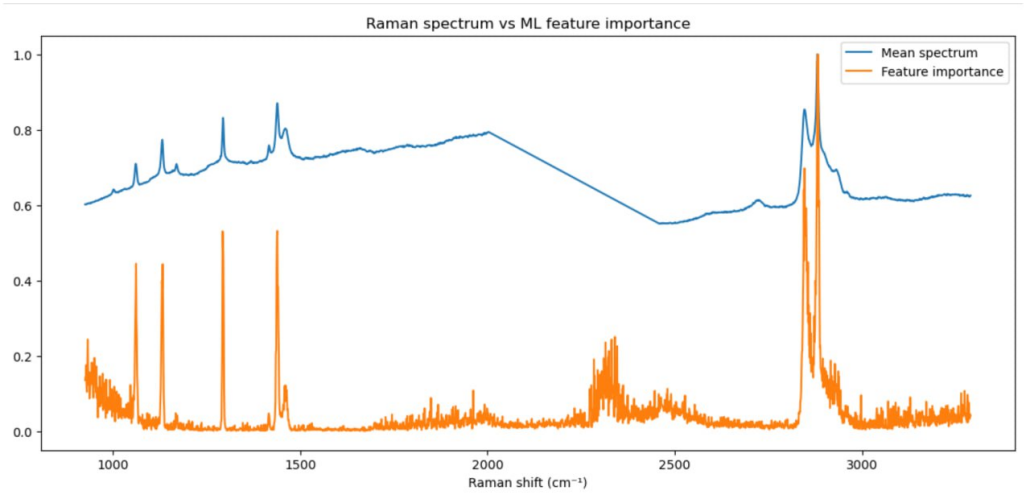

Рис. 4: Распределение полезности параметра для модели

На данном рисунке оранжевым показано насколько важна для нейросети та или иная `feature`.

2.1 Интерпретация значимых спектральных признаков

На графике видно, что модель опирается на конкретные химические маркеры:

- **2800–3000 см$^{-1}$ (Самый важный участок):** Это область валентных колебаний $C - H$. Пик 2930 см$^{-1}$ от-

вечает за белки, а 2850 и 2880 см$^{-1}$ — за липиды. То, что здесь самая высокая важность, говорит о том, что разница в концентрации белков и жиров — ключевой признак для классификации.

- **1440–1450 см$^{-1}$:** Деформационные колебания CH_2 и CH_3. Это «универсальный» сигнал органики, указывающий на изменения в структуре мембран или белкового матрикса.
- **1300 см$^{-1}$:** Соответствует липидам или Амиду III (белки). Помогает модели отслеживать конформационные изменения молекул.
- **1000–1150 см$^{-1}$:** Здесь важен пик фенилаланина (1003 см$^{-1}$) и скелетные колебания $C-C$ связей (1130 см$^{-1}$).