Задача по Комбинационному рассеянию света

IT-дно

Пантенков Роман

Садиковская Елизавета

Приходько Павел

07.03.2026

1 Описание подхода

1.1 Предобработка

1. Для начала мы собираем всю информацию со свех файлов что у нас есть. Те точки для которых <= 10 измерений мы отбрасываем, а остальные точки мы группируем по областям мозга и по классам.

2. Дальше мы интерполируем значения intensity и вычисляем их при wave = 900, wave = 901, ... , wave = 3500. На данном этапе наш датафрейм состоит из колонок: wave900, ... , wave3500, brain_region, wave_category, class.

3. Чтобы увеличить гладкость графика и понизить влияние флуорисцентного излучения, мы сглаживаем значения с помощью фильтра Савицкого-Голея, корректируем `baseline` с помощью ARPLS, обнуляем минимум и убираем отрицательные значения, и векторно нормализуем (L2)

4. Далее, перед обучением мы нормализуем числовые значения и с помощью `OHE` кодируем `brain_reigon`. Также мы выбрасываем промежуток с 2000 по 2400, так как в нем у нас нет нормальных данных.

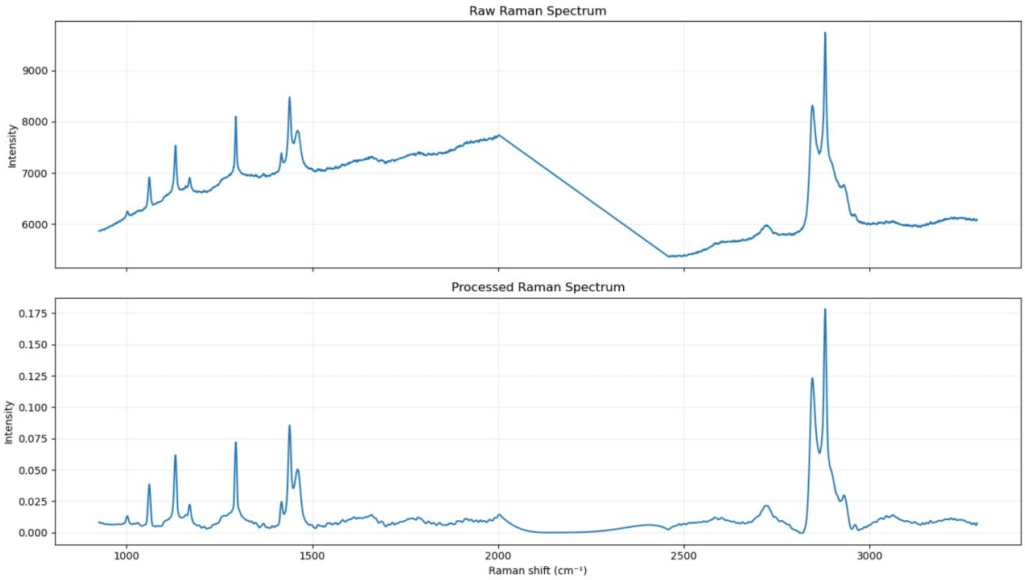

Рис. 1: До/после препроцессинга

Также, по началу мы использовали `PCA`, он давал хороший прирост точности модели, так как делал данные более независимыми, однако мы решили отказаться от его использования, ведь для дополнительного задания нам нужно было определить наиболее важные параметры (что явно несовместимо с `PCA`)

1.2 Тип модели и тренировка

Мы опробовали большое количество разных моделей, но в итоге остановились на `RandomForestClassifier`. Он позволяет сосредоточиться только на важных спектрах и при этом не слишком сильно переобучается.

1.3 Полученные метрики

Мы прогнали нашу модель через кросс-валидацию

```
CV scores: [0.81570824 0.81387904 0.81683055 0.81580151 0.80997027]
Mean CV: 0.8144379239129413
```

Так-же мы получили остальные метрики:

```
Training RandomForest...
Training trees: 100%|██████████| 300/300 [08:55<00:00,  1.79s/it]
              precision    recall  f1-score   support

     control       0.84      0.79      0.81      6300
        endo       0.87      0.80      0.83      5828
         exo       0.77      0.86      0.81      6615

    accuracy                           0.82     18743
   macro avg       0.82      0.82      0.82     18743
weighted avg       0.82      0.82      0.82     18743

Top 20 important features:
brain_region_cerebellum    0.025083
wave2882                   0.008993
wave2880                   0.008759
wave2881                   0.008513
wave2883                   0.008113
brain_region_cortex        0.007792
wave2846                   0.006277
wave2879                   0.005934
wave2844                   0.005796
wave2885                   0.005504
brain_region_striatum      0.005486
wave2884                   0.005355
wave2850                   0.005321
wave2878                   0.005233
wave2849                   0.004977
wave2847                   0.004917
wave2851                   0.004801
wave1439                   0.004760
wave1293                   0.004727
wave2848                   0.004676
dtype: float64
```

Рис. 2: Метрики

2 Дополнительное задание

Мы нашли наиболее важные для нас частоты:

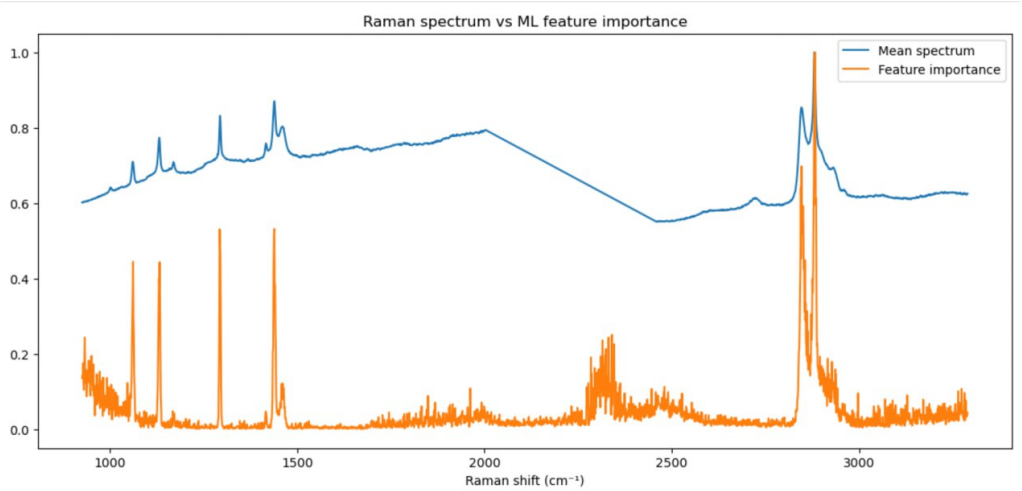

Рис. 3: Распределение полезности параметра для модели

На данном рисунке оранжевым показано насколько важна для нейросети та или иная `feature`.

2.1 Интерпретация значимых спектральных признаков

На графике видно, что модель опирается на конкретные химические маркеры:

- **2800–3000 см$^{-1}$ (Самый важный участок):** Это область валентных колебаний $C-H$. Пик 2930 см$^{-1}$ отвечает за белки, а 2850 и 2880 см$^{-1}$ — за липиды. То, что здесь самая высокая важность, говорит о том, что разница в концентрации белков и жиров — ключевой признак для классификации.
- **1440–1450 см$^{-1}$:** Деформационные колебания CH_2 и CH_3. Это «универсальный» сигнал органики, указывающий на изменения в структуре мембран или белкового матрикса.
- **1300 см$^{-1}$:** Соответствует липидам или Амиду III (белки). Помогает модели отслеживать конформационные изменения молекул.
- **1000–1150 см$^{-1}$:** Здесь важен пик фенилаланина (1003 см$^{-1}$) и скелетные колебания $C-C$ связей (1130 см$^{-1}$).